

提交说明文档

第六届计图挑战赛 赛道一 A 榜代码检查材料 (dataset1 部分)

1. 团队信息

- 团队名称：飞带快友队
- 参赛赛道：赛道一（基于图学习的动态推荐任务）
- A 榜排名：第 31 名
- A 榜最优总分：1.4081054563093174
- 联系人：李佩霖
- 联系方式：微信 lplakimo, 电话 13844896827
- 本文档负责部分：dataset1（队友负责 dataset2，单独提交）

2. 项目概述

本赛题要求给定历史时序交互 (src, dst, time)，对测试集中每个 (src, time) 的 100 个候选 dst 输出交互概率分布，评测指标为 MRR。

针对 dataset1（非二部图，src/dst

共享节点集合，重复边比例高、以“记忆型”模式为主），我们的方案为：

- **节点特征**：Node2Vec (node2vec 0.5.0, $p=q=1$ 即经典 DeepWalk 设定：每节点 200 条 $\times$ 30 步随机游走 + skip-gram Word2Vec, window=10、min_count=1, 256 维) 从训练图结构学习节点嵌入，L2 归一化后作为模型的初始化特征；
- **模型**：GraphMixer (Jittor 实现) ——将每个源节点最近 40 条交互目标编码为序列，经正弦位置编码与 2 层 MLP-Mixer (token-mixing + channel-mixing, 双残差) 提取时序模式，再用“位置指数衰减 $\times$ 时间间隔 recency”加权平均池化得到历史记忆向量；查询向量 = 源节点嵌入 + 历史投影；候选打分使用 MLP scorer，并融合 3 维启发式特征（候选节点 degree、popularity、(src, dst) 历史边计数）；
- **训练**：listwise 交叉熵（温度 0.1）+ $0.2 \times$ BPR margin loss，时间切分 85%/15% 验证选优；采用**两阶段训练**——第一阶段从头训练 20 epochs，第二阶段加载第一阶段最优 checkpoint 续训 10 epochs；
- **推理**：对 100 个候选打分后转换为行内分位数（同分按候选 ID 打破平局，保证确定性），按赛题格式输出。

3. 代码结构说明

```
code/
gen_features.py      # 节点特征生成：Node2Vec 随机游走 + skip-gram Word2Vec，输出 node_features_dataset1_n2v256.npy
precompute_heuristics.py # 启发式特征预计算：degree / popularity / edge_count
```

```
model_graphmixer_jt.py # GraphMixer 模型定义 (Jittor) : MixerBlock、MLPScorer、GraphMixerModel
train_graphmixer_jt.py # 训练 + 验证选优 + 测试推理主流程, 生成提交文件 dataset1.csv
compare_results.py    # (辅助工具) 两个结果文件的一致性对比, 非流水线必需
```

关键模块逻辑:

- `train_graphmixer_jt.py::build_histories_with_time` : 按时间顺序构建每个源节点的最近 40 条历史交互及 $\log_{1p}$ 时间间隔 (90 分位归一化), 严格只用当前时刻之前的信息, 无时间泄漏;
- `GraphMixerModel.encode_history` : 历史序列嵌入 + 位置编码 + MLP-Mixer + 时间加权池化;
- `GraphMixerModel.score` : query 与候选嵌入 + 启发式特征经 MLP 打分;
- 训练使用 Adam ($lr=1e-3$, $weight_decay=1e-6$), $batch_size=2048$, 每样本 31 个随机负例 (避开 padding 0 与正例碰撞);
- 推理输出经 `rank_percentiles` 转为 (0,1] 分位数后写出, 与 A 榜提交格式一致 (100 列、8 位小数)。

4. 环境配置步骤

- 操作系统: Ubuntu 22.04 (亦在 Windows 11 + Anaconda 下验证通过)
- Python: 3.10 (本地训练使用 3.9.25, 代码无版本特性依赖)
- CUDA: 12.4 (本地训练为 RTX 3070 Laptop; 审核环境 NVIDIA 4090 可直接运行)
- 依赖安装: `pip install -r requirements.txt`
- `jittor>=1.3.10` (本地实际使用 1.3.8.5, API 兼容)
- `numpy / pandas / scipy / scikit-learn / gensim>=4.3,<5 / node2vec==0.5.0 / networkx / tqdm`
- Jittor 安装注意事项: 需 `gcc/g++ ≤ 10` 与 `libomp` (参考 Jittor 官方文档); 项目路径必须为纯 ASCII (中文路径会导致 Jittor JIT 编译失败);
- 本项目未使用 `JittorGeometric` (`dataset1` 方案不依赖该库)。

5. 运行步骤

数据准备: 将官方 `dataset1/train.csv`、`dataset1/test.csv` 放入工作目录的 `dataset1/` 下, `code/` 内脚本放工作目录根。

```
# 步骤 1: 生成节点特征 (CPU, node2vec 库游走采样较慢, 约 1-2 小时;
# 本包已附生成好的 node_features_dataset1_n2v256.npy, 可跳过本步)
python gen_features.py --dataset dataset1 --data_dir .

# 步骤 2: 预计算启发式特征 (约 1 分钟)
python precompute_heuristics.py --dataset dataset1 --data_dir . --shared_nodes

# 步骤 3: 第一阶段训练 (GPU, RTX 3070 Laptop 约 20 分钟)
python train_graphmixer_jt.py \
--dataset dataset1 --data_dir . --shared_nodes --use_heuristics \
```

```
--node_features ./node_features_dataset1_n2v256.npy \
--save_dir ./saved_gm_d1_final \
--hidden_dim 256 --history_length 40 --batch_size 2048 --epochs 20 \
--lr 1e-3 --num_negatives 31 --val_samples 4000 \
--num_layers 2 --mlp_ratio 2.0 --dropout 0.1
```

步骤 4: 第二阶段续训 (加载第一阶段最优 checkpoint 再训 10 epochs, 约 10 分钟)

```
python train_graphmixer_jt.py \
--dataset dataset1 --data_dir . --shared_nodes --use_heuristics \
--node_features ./node_features_dataset1_n2v256.npy \
--save_dir ./saved_gm_d1_final \
--init_checkpoint ./saved_gm_d1_final/dataset1_graphmixer.pkl \
--hidden_dim 256 --history_length 40 --batch_size 2048 --epochs 10 \
--lr 1e-3 --num_negatives 31 --val_samples 4000 \
--num_layers 2 --mlp_ratio 2.0 --dropout 0.1
```

快速验证 (可选): 使用本包所附 checkpoint 直接推理, 约 2 分钟即可复现 A 榜提交结果:

```
python train_graphmixer_jt.py \
--dataset dataset1 --data_dir . --shared_nodes --use_heuristics \
--node_features ./node_features_dataset1_n2v256.npy \
--save_dir ./saved_verify \
--init_checkpoint ./dataset1_graphmixer.pkl \
--hidden_dim 256 --history_length 40 --batch_size 2048 --epochs 0 \
--lr 1e-3 --num_negatives 31 --val_samples 4000 \
--num_layers 2 --mlp_ratio 2.0 --dropout 0.1
```

输入输出说明:

- 输入: dataset1/train.csv (src,dst,time) 、 dataset1/test.csv (src,time,c1..c100)
- 中间产物: node_features_dataset1_n2v256.npy 、 heuristics_dataset1_* 、 saved_gm_d1_final/dataset1_graphmixer.pkl (最优 checkpoint) 与 _meta.npy
- 最终输出: saved_gm_d1_final/dataset1.csv (61,051 行 × 100 列, 8 位小数), 即 A 榜提交格式结果文件

关键超参数: hidden_dim=256、history_length=40、num_layers=2、mlp_ratio=2.0、dropout=0.1、temperature=0.1、time_decay=0.5、batch_size=2048、lr=1e-3、num_negatives=31、两阶段 epochs=20+10。

每个阶段结束后脚本自动加载验证集 MRR 最优的 checkpoint 进行测试推理。期望本地验证 MRR: 第一阶段 ≈0.988, 第二阶段 ≈0.991 (实测: 从头两阶段复现 0.990792; 原始训练 meta 记录 0.990958)。

6. 复现验证与补充

- **复现验证**: 在干净目录 (纯 ASCII 路径) 按上述步骤从头完整重跑通过 (两阶段后 val MRR=0.990792, 与原始训练的 0.990958 一致); 用本包所附 checkpoint 在 history_length=40 配置下直接推理, 输出与 A 榜实际提交文件 **top-1 候选一致率 99.98%、行内 Pearson 相关 1.0000** (可用 compare_results.py --a <提交文件> --b <复现文件> 复验)。注: 两次独立训练的模型对候选尾部排序会有差异, 从头重训的预测文件与提交文件逐行对比一致率约 88% 属正常, 复现成功应以验证集 MRR 为准;

- **随包附件：** `node_features_dataset1_n2v256.npy` (44MB, 步骤 1 产物) 与 `dataset1_graphmixer.pkl` (48MB, 步骤 4 产物) 已放入 zip 根目录, 便于审核快速复现; 二者均可由上述脚本从原始数据独立重新生成;
- **特征生成的非确定性：** node2vec 0.5.0 采样使用 `workers=4` 并行, 重新生成的特征与附件存在小偏差, 但重训后指标相当; Jittor CUDA 训练亦存在固有的非逐位确定性, 多次运行指标波动在 ± 0.002 MRR 内;
- **无测试集标签使用：** 全部特征仅由 `train.csv` 构建; `test.csv` 仅读取候选列做推理; 验证集为训练集时间切分的最后 15%;
- **无外部数据：** 未使用赛方提供数据之外的任何数据;
- **已知问题：** Windows 下运行需保证路径纯 ASCII; Jittor 首次运行若提示 "jit_utils updated, please rerun", 重新执行同一命令即可。